

1. Visão Geral do Projeto

- **Objetivo:** Analisar o perfil de risco e inadimplência de clientes
- **Fontes de Dados:** Base em CSV retirada do [Kaggle.com](https://www.kaggle.com)

2. Dicionário de Dados (O Glossário)

ID: Código identificador exclusivo e sequencial gerado para cada registro da tabela (Formato: OX1602, OX1603...).

ID_do_cliente: Código de identificação único do cliente, utilizado para agrupar o histórico e calcular métricas consolidadas (como a moda).

Mês: O mês de referência da coleta dos dados e de comportamento daquele registro.

Nome: Nome completo do cliente cadastrado.

Idade: Idade cronológica do cliente (em anos).

Ocupação: Profissão ou área de atuação do cliente.

Renda_anual: Renda bruta total acumulada pelo cliente ao longo de um ano.

Salário_líquido_mensal: Valor líquido recebido mensalmente pelo cliente, já corrigido na escala decimal de duas casas.

Número_de_contas_bancárias: Quantidade de contas bancárias ativas em nome do cliente.

Números_de_cartão_de_crédito: Quantidade de cartões emitidos e vinculados ao cliente.

Taxa_de_juros: Taxa de juros média aplicada aos produtos contratados pelo cliente.

Número_de_empréstimo: Quantidade de empréstimos ativos contratados pelo cliente (valores inválidos foram tratados via moda do cliente).

Dias_de_atraso_após_vencimento: Quantidade média de dias que o cliente costuma atrasar o pagamento de suas contas (valores negativos foram corrigidos via moda).

Num_pagamento_atrasado: Número total de faturas ou parcelas pagas com atraso pelo cliente (valores negativos foram corrigidos via moda).

Número_de_consultas_de_crédito: Quantidade de vezes que o histórico de crédito do cliente foi consultado por instituições financeiras (outliers acima de 180 foram mitigados).

Dívida_restante: Valor monetário total que o cliente ainda deve em aberto no mercado.

Tempo_histórico_de_crédito: Tempo de existência do histórico de crédito do cliente na base do mercado (geralmente medido em meses ou anos).

Pagamento_mínimo: Indicador que aponta se o cliente costuma pagar apenas o valor mínimo da fatura do cartão de crédito.

Total_da_parcela_mensal: Soma dos valores de parcelas de empréstimos e financiamentos devidos mensalmente (valores bizarros acima de 14.511 foram corrigidos).

Aporte_mensal: Valor médio que o cliente investe ou poupa mensalmente.

Monthly_balance: Saldo financeiro restante no mês após o salário líquido deduzir os gastos e obrigações básicas.

Credit_Score: Classificação do perfil de crédito do cliente em categorias de risco (Péssimo [Poor], Padrão [Standard], Bom [Good]). É a variável resposta do dashboard.

Colunas Criadas e Auxiliares (Power BI)

Faixa_etária: Categoria textual que agrupa os clientes por blocos de idade (Ex: 10 a 19 anos, 20 a 29 anos...).

Faixa_taxa: Agrupamento em intervalos textuais para as taxas de juros enfrentadas pelos clientes (Ex: 11% a 20%).

Status_outliers_renda: Coluna gerada por regra estatística (IQR) que classifica a linha como "Normal" ou "Outlier" com base na renda anual.

Faixa_taxa_outliers: Coluna de controle para mapear e isolar taxas de juros fora do padrão estatístico comum.

Faixa_de_renda: Categoria que agrupa a Renda Anual em blocos de valores (Ex: 0 a 10 mil reais, 10 a 25 mil reais...).

Faixa_etária_ordem: Coluna numérica auxiliar com pesos de 1 a 7, criada unicamente para garantir a ordenação cronológica correta dos gráficos de Faixa Etária.

Faixa_taxa_ordem: Coluna numérica auxiliar usada para ordenar as faixas de taxa de juros do menor para o maior nos visuais.

Faixa_de_renda_ordem: Coluna numérica auxiliar com pesos de 1 a 7, criada para alinhar as barras de Faixa de Renda da menor para a maior no dashboard.

3. Engenharia e Tratamento de Dados

Nesta etapa, o objetivo principal foi realizar o saneamento, a padronização e a limpeza da base de dados original utilizando a biblioteca Pandas. Como a base possui um histórico mensal repetido por cliente (**ID_do_cliente**), as regras de negócio foram desenhadas para preservar a consistência e a individualidade de cada perfil antes da exportação para o Power BI. As seguintes tratativas foram aplicadas:

Remoção de Colunas Improdutivas

As colunas que foram completamente removidas do DataFrame são:

- **SSN**: Excluída por questões de segurança da informação (LGPD/Privacidade), por se tratar de um dado sensível de identificação governamental e que não possuía valor analítico para o modelo de risco.
- **Comportamento_de_pagamento**: Removida devido ao alto índice de inconsistências ou por redundância frente a outras variáveis de atraso mais precisas já presentes no modelo.
- **'Mudança_de_limite_de_crédito', 'Taxa_Utilização_Crédito', 'Mix_de_crédito', 'Tipo_de_empréstimo'**: Removida para reduzir os dados a serem exportados e otimizar as análises.

Tratamento de Outliers (Método Estatístico IQR)

Para evitar distorções gritantes nas análises de médias e tendências de renda no Dashboard, foi aplicado o método do **Intervalo Interquartil (IQR - Interquartile Range)** nas variáveis financeiras **Renda_anual** e **Salário_líquido_mensal**.

- Foram calculados os limites inferior ($\$Q1 - 1.5 \times IQR$) e superior ($\$Q3 + 1.5 \times IQR$) de toda a base.
- Os registros com valores acima do teto superior foram removidos, filtrando a base para refletir o comportamento do cliente padrão e eliminando ruídos de valores discrepantes (potenciais erros de digitação ou extremos fora da realidade do escopo).

Imputação de Dados Inconsistentes e Nulos pela Moda do Cliente

Detectou-se que diversas colunas possuíam valores corrompidos (nulos, negativos impossíveis ou inteiros fora do comum). Para não descartar essas linhas e perder histórico, aplicou-se uma regra: substituir o valor incorreto pela moda (o valor que mais se repete) vinculada estritamente ao **ID_do_cliente** daquela linha.

- **Número_de_empréstimo**: Registros com o valor padrão -100 foram substituídos pela moda de empréstimos reais do próprio cliente.
- **Dias_de_atraso_após_vencimento** e **Num_pagamento_atrasado**: Valores negativos (erros de sinal) foram substituídos pela moda do histórico de atraso do cliente.

- **Número_de_consultas_de_crédito:** Valores bizarros e irreais acima de 180 consultas foram mitigados e substituídos pela moda de consultas daquele ID de cliente.
- **Total_da_parcela_mensal:** Tetos absurdos que ultrapassavam 14.511 foram limpos utilizando a moda das parcelas usuais do cliente.
- **Salário_líquido_mensal:** Linhas remanescentes com valores nulos (NaN) foram preenchidas usando a moda salarial histórica calculada para o respectivo cliente.

Reordenação e Formatação de Chave Primária (ID)

Para garantir uma estrutura de banco de dados íntegra e sequencial:

- A base foi ordenada de forma crescente com base em seu campo indexador original.
- O campo **ID** foi inteiramente reconstruído de forma limpa, seguindo o padrão textual de negócios e iniciando estritamente a partir da sequência incremental: OX1602, OX1603, OX1604, OX1605, sucessivamente.

4. Modelagem e Regras no Power BI

Após a importação da tabela '**base_dados_tratada - Versão Final**', a inteligência de negócios foi construída diretamente no Power BI utilizando **Linguagem DAX** para a criação de métricas agregadas e colunas calculadas de segmentação.

Métricas Criadas (Medidas DAX)

As medidas foram desenvolvidas para garantir cálculos dinâmicos que reagem instantaneamente aos filtros e segmentadores do dashboard, utilizando boas práticas de performance.

- **Contagem de Clientes Únicos (Qtd_Clientes_Unicos)**
 - Snippet de código:
 - Qtd_Clientes_Unicos = DISTINCTCOUNT('base_dados_tratada - Versão Final'[ID_do_cliente])
 - **Porquê:** Como a base é histórica e possui múltiplas linhas mensais para o mesmo cliente, uma contagem simples (**COUNT**) inflaria os números. Esta medida garante o tamanho real da carteira de clientes ativos analisada.
- **Percentual de Inadimplência (%_Inadimplencia)**
 - Snippet de código

%_Inadimplencia =
VAR ClientesPoor =

```

CALCULATE(
    DISTINCTCOUNT('base_dados_tratada - Versão Final'[ID_do_cliente]),
    'base_dados_tratada - Versão Final'[Credit_Score] = "Poor"
)
VAR TotalClientes = [Qtd_Clientes_Unicos]
RETURN
    DIVIDE(ClientesPoor, TotalClientes, 0)

```

- **Porquê:** É o principal KPI de risco do negócio. Utiliza a função **DIVIDE** para evitar erros matemáticos de divisão por zero caso a base seja totalmente filtrada. Ela isola o volume de clientes com score "Péssimo" e mede sua representatividade no todo.

- **Média Geral de Dias de Atraso (**Media_Dias_Atraso**)**
 - Snippet de código: `Media_Dias_Atraso = AVERAGE('base_dados_tratada - Versão Final'[Dias_de_atraso_após_vencimento])`
 - **Porquê:** Fornece a métrica de comportamento temporal de pagamento. Serve como termômetro de alerta para a equipe de cobrança e risco.

Colunas Calculadas e Engenharia de Ordenação

Para enriquecer a capacidade de descoberta do dashboard, os dados contínuos de Idade e Renda foram transformados em faixas categóricas.

- **Segmentação por Faixa Etária e Faixa de Renda (**SWITCH**):** Agrupou os clientes em blocos estratégicos (ex: "10 a 19 anos", "20 a 29 anos" / "0 a 10 mil reais", "10 a 25 mil reais") permitindo visões demográficas macro.
- **A Solução de Ordenação Lógica (**Faixa_etária_ordem**, **Faixa_taxa_ordem** e **Faixa_de_renda_ordem**):** Por padrão, o Power BI ordena textos de forma alfabética, o que faria a faixa "150 mil ou mais" aparecer antes de "20 mil reais", destruindo a lógica do gráfico. Para corrigir isso, foram criadas colunas de peso numérico (1 a 7) atreladas às faixas originais usando o recurso **"Classificar por coluna"**. Isso forçou os gráficos a exibirem as distribuições de forma estritamente crescente e intuitiva.

5. Insights de Negócio

Nota: Esta seção resume os principais achados extraídos do cruzamento de dados comportamentais e demográficos da carteira, desenhando o retrato do risco de crédito da instituição.

O Perfil de Maior Risco: Concentração na População Jovem

Os dados do dashboard comprovam que **os clientes mais jovens são os maiores detratores do score de crédito** da carteira. Esse grupo específico apresenta sinais claros de descontrole financeiro quando comparado à média geral:

- Possuem, em média, mais contas bancárias abertas (**7 contas**) e operam com mais cartões de crédito (**6,9**).
- Devido ao alto risco que representam, são empurrados para as piores condições do mercado, lidando com taxas de juros agressivas entre **21% e 30%**.

Os Fatores que Sufocam o Score e Geram Clientes "Péssimo"

Ao isolar o grupo com a pior classificação de crédito (*Péssimo*), identificamos os gatilhos que mais influenciam a queda do score. O perfil "Péssimo" não é definido apenas por baixa renda, mas sim por um **comportamento de superendividamento simultâneo**:

- **Abuso de Linhas de Crédito:** Registram média de **6,6 cartões e 4,5 empréstimos ativos**.
- **Explosão de Consultas:** Passam por uma média de **81 consultas de crédito** no mercado, sinalizando desespero financeiro para o algoritmo de score.

Correlação Direta: Estrutura Enxuta vs. Estrutura Sobrecarregada

Existe uma barreira perfeitamente visível que separa os bons dos maus pagadores na modelagem:

- **Bons Pagadores:** Mantêm uma vida financeira minimalista e controlada. Têm em média apenas **3 contas bancárias, 4 cartões e 2 empréstimos**, o que lhes garante taxas de juros saudáveis (entre **6% e 10%**).
- **Inadimplentes:** Dobram ou triplicam essa estrutura, operando sufocados pelo volume de linhas paralelas e juros altos (até **30%**).

O Impacto Crítico do Atraso de Pagamento

A pontualidade é o fator de maior peso. O cliente classificado como *Poor* demora quase o **triplo do tempo** para regularizar suas pendências em relação ao bom pagador:

- Enquanto o cliente *Bom* resolve seus atrasos em média em **11 dias** (acumulando 7,7 faturas), o cliente *Péssimo* arrasta sua dívida por **30 dias** acumulando **14,4 faturas em atraso**.

Recomendação Estratégica

A instituição deve aplicar políticas de concessão de crédito mais rígidas para o público jovem ou perfis que comecem a abrir a 5ª ou 6ª conta bancária no mercado, limitando o número de cartões disponíveis para evitar o efeito cascata que destrói a capacidade de pagamento do cliente.

Projeto executado por: *Melissa Gameleira*